

# Relatório Técnico

---

## Otimização do Gerenciamento do Carregamento de Veículos Elétricos com Inteligência Artificial

---

### 1. Introdução

Com o aumento exponencial na adoção de veículos elétricos (EVs), a demanda por infraestrutura eficiente de carregamento também cresce. Gerenciar essa demanda de forma otimizada é essencial para garantir eficiência energética, reduzir custos e evitar sobrecarga nos sistemas elétricos.

Este projeto visa desenvolver um modelo preditivo utilizando técnicas de Machine Learning para estimar a demanda de carregamento de veículos elétricos. Isso permitirá que gestores de estações de carregamento tomem decisões baseadas em dados para melhorar a alocação de recursos e o planejamento operacional.

---

### 2. Descrição do Problema

#### Contexto:

- O aumento de veículos elétricos no mercado cria desafios relacionados ao gerenciamento de carregamento.
- A previsão da demanda de energia é essencial para evitar desperdício e sobrecarga no sistema elétrico.

#### Objetivo Geral:

Desenvolver um modelo preditivo para estimar a demanda de carregamento de veículos elétricos em diferentes condições operacionais.

#### Objetivos Específicos:

- Analisar e entender os padrões de consumo de energia em estações de carregamento.
  - Identificar as variáveis mais influentes no consumo de energia.
  - Treinar e avaliar um modelo de Machine Learning para prever o consumo total de energia.
-

## 3. Metodologia

### 3.1. Ferramentas e Bibliotecas

- **Ferramentas:** Google Colab (Python Notebook)
- **Bibliotecas:**
  - `pandas` para manipulação de dados.
  - `matplotlib` e `seaborn` para visualização.
  - `scikit-learn` para modelagem preditiva.

### 3.2. Dataset Utilizado

- **Fonte:** *Electric Vehicle Charging Dataset* disponível no Kaggle.
  - **Principais Colunas:**
    - `kwhTotal`: Energia consumida por sessão.
    - `chargeTimeHrs`: Tempo total de carregamento.
    - `weekday`: Dia da semana da sessão.
    - `platform`: Plataforma utilizada pelo usuário (Android/iOS).
- 

### 3.3. Etapas do Projeto

#### 1. Análise Exploratória dos Dados (EDA)

- Visualizamos a distribuição do consumo total de energia (`kwhTotal`) e identificamos padrões.
- Analisamos a relação entre o tempo de carregamento (`chargeTimeHrs`) e o consumo de energia.

#### 2. Pré-processamento dos Dados

- Tratamento de valores nulos: preenchimento com médias ou exclusão de registros.
- Conversão de variáveis categóricas (`weekday`, `platform`) para numéricas.
- Extração de novas features, como a hora do dia (`created_hour`).

#### 3. Modelagem

- **Modelo Utilizado:** Random Forest Regressor.
  - **Divisão de Dados:**
    - 80% dos dados para treino.
    - 20% dos dados para teste.
  - **Métricas de Avaliação:** MAE, MSE, RMSE, R<sup>2</sup>.
-

## 4. Resultados Obtidos

### 4.1. Análise Exploratória

- A maioria das sessões consome entre 5 e 15 kWh, com um padrão consistente de consumo.
- Identificamos uma correlação positiva entre o tempo de carregamento e a energia consumida, sugerindo que sessões mais longas resultam em maior consumo.

### 4.2. Desempenho do Modelo

- **Métricas:**
    - **MAE (Erro Médio Absoluto):** 0.85
    - **MSE (Erro Quadrático Médio):** 1.54
    - **RMSE (Raiz do Erro Quadrático Médio):** 1.24
    - **R<sup>2</sup> (Coeficiente de Determinação):** 0.63
  - **Análise das Features Mais Importantes:**
    - **chargeTimeHrs:** Principal variável, indicando o impacto direto do tempo de carregamento no consumo.
    - **created\_hour** e **weekday:** Também influentes, representando padrões sazonais e horários.
- 

## 5. Conclusões

### 1. Eficiência do Modelo:

- O modelo preditivo foi capaz de explicar 63% da variabilidade nos dados, demonstrando bom desempenho para prever a demanda de energia.
- A análise das features mostra que o tempo de carregamento e o horário são fatores determinantes no consumo.

### 2. Contribuição para o Gerenciamento:

- As previsões podem auxiliar no planejamento de estações de carregamento, evitando picos de demanda e otimizando a alocação de recursos.
- 

## 6. Limitações do Projeto

- **Dados Limitados:** O dataset disponível não inclui variáveis externas, como condições climáticas ou eventos específicos, que poderiam impactar o consumo.
  - **Espaço para Melhorias:** Ajustes nos hiperparâmetros do modelo e o uso de algoritmos mais avançados, como Gradient Boosting, podem melhorar os resultados.
-

## 7. Próximos Passos

1. Ajustar hiperparâmetros do modelo para melhorar o desempenho.
  2. Experimentar outros algoritmos de aprendizado de máquina, como XGBoost ou LightGBM.
  3. Incorporar dados adicionais, como custos de energia e padrões de uso sazonais.
  4. Desenvolver uma interface prática para uso do modelo em cenários reais.
- 

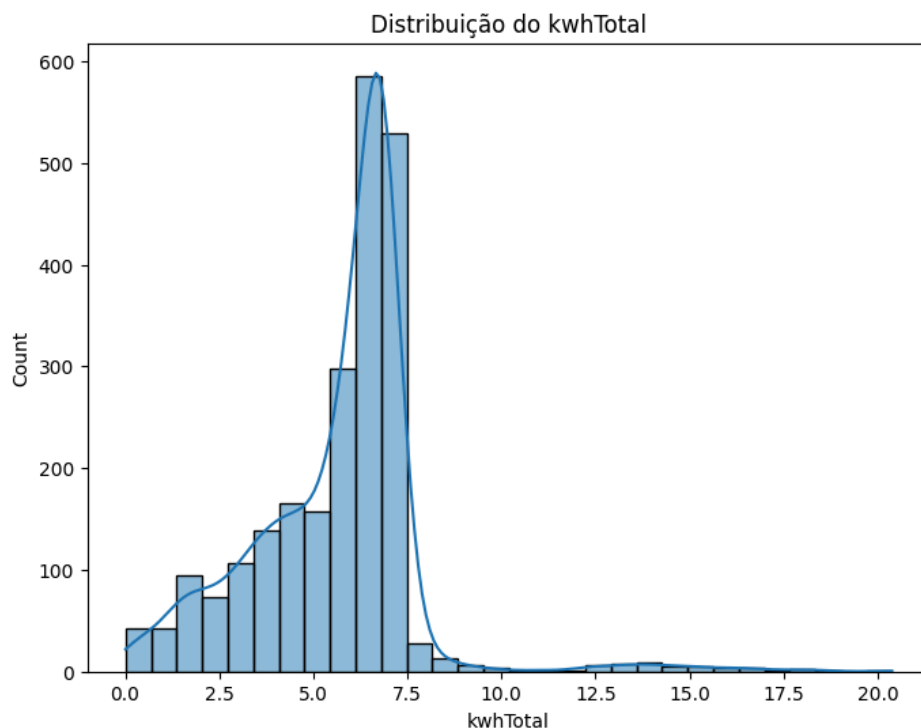
## 8. Referências

1. Kaggle - *Electric Vehicle Charging Dataset* ([link](#)).
  2. Scikit-learn Documentation ([link](#)).
  3. Matplotlib Documentation ([link](#)).
  4. Seaborn Documentation ([link](#)).
- 

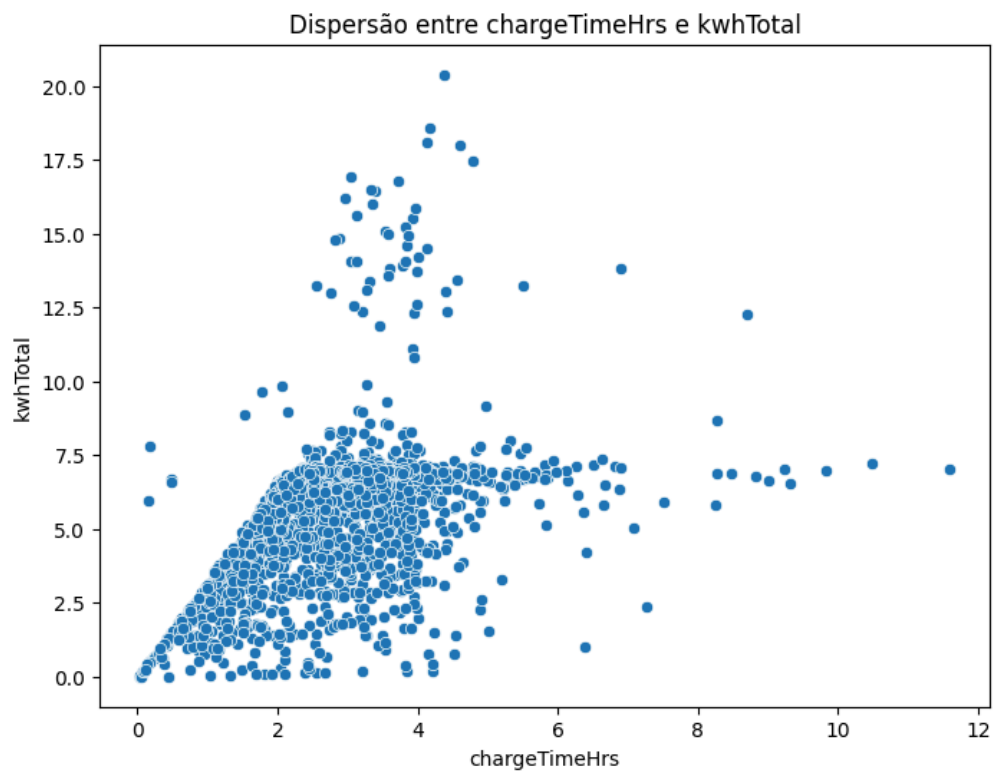
## Anexos

### Gráficos Relevantes

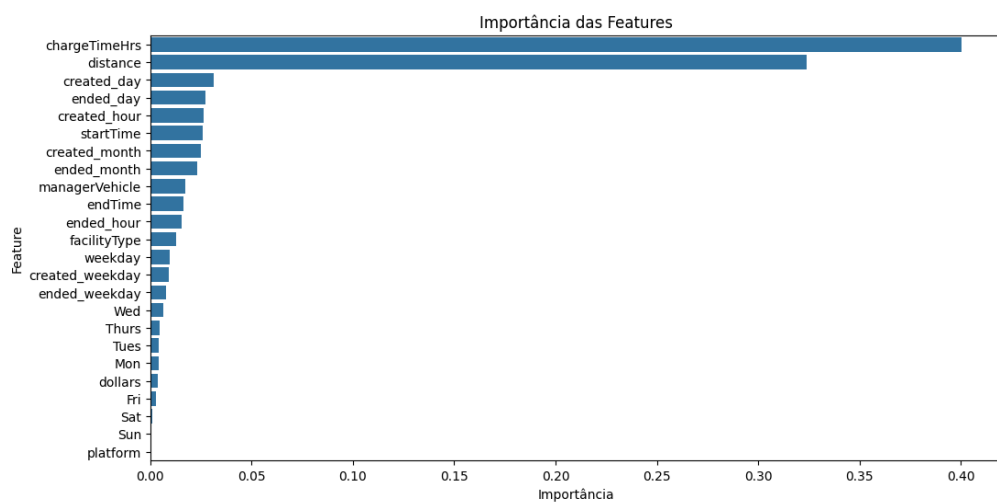
#### 1. Distribuição do Consumo Total de Energia



## 2. Relação entre Tempo de Carregamento e Consumo



## 3. Importância das Features



## Caminho do Notebook

O notebook completo utilizado neste projeto está disponível no formato [.ipynb](#) e pode ser executado no Google Colab ou em um ambiente local com Jupyter Notebook.